

线性分类器

翟婷婷

扬州大学
信息工程（人工智能）学院
zh tt@yzu.edu.cn

2022年春

课程目标

- 掌握线性判别函数的一般表达和参数的几何意义
- 理解线性可分和线性不可分问题
- 了解广义线性化的思想
- 掌握线性判别函数值的几何意义

线性判别函数


➤ 在 d 维的特征空间中，**线性判别函数**的一般形式为：

$$G(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$$

其中， $\mathbf{w} = [w_1, w_2, \dots, w_d]^T$ 称为权向量， b 称为偏置。

(\mathbf{w}, b) 是判别函数的参数，需要通过自主学习得到。

$G(\mathbf{x})$ 将特征空间划分为两个决策域： $G(\mathbf{x}) > 0$ 和 $G(\mathbf{x}) < 0$ ，而 $G(\mathbf{x}) = 0$ 是**决策边界方程**。



线性判别函数加上对应的分类决策规则，就构成**线性分类器**。

线性分类决策边界

- 在 d 维的特征空间中，线性分类决策边界的表达式为：

$$G(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b = 0$$

- 当 $d = 1$, 决策边界是一个点:

$$x = -\frac{b}{w}$$

- 当 $d = 2$, 决策边界是一条直线:

$$w_1 x_1 + w_2 x_2 + b = 0$$

- 当 $d = 3$, 决策边界是一个平面:

$$w_1 x_1 + w_2 x_2 + w_3 x_3 + b = 0$$


- 当 $d > 3$, 决策边界是一个超平面:

$$\mathbf{w}^T \mathbf{x} + b = 0$$

线性可分vs线性不可分问题

- 以二分类问题为例：如果一个二分类问题能够找到一个**线性判别函数 $G(\mathbf{x})$** 将两类实例分得开，那么该二分类问题是**线性可分的**，否则就是**线性不可分的**。

Linear vs. nonlinear problems




线性不可分问题

➤ 通过非线性判别函数进行分类:

$$\mathbf{x} = (x_1, x_2)$$

$$\begin{aligned} G(\mathbf{x}) &= x_1 x_2 \\ \mathbf{x} \in \omega_1, G(\mathbf{x}) &> 0 \\ \mathbf{x} \in \omega_2, G(\mathbf{x}) &< 0 \end{aligned}$$


$$\begin{aligned} G(x) &= (x - a)(x - b) \\ x \in \omega_1, G(x) &> 0 \\ x \in \omega_2, G(x) &< 0 \end{aligned}$$



非线性判别函数的训练方法比线性判别函数的训练方法复杂的多!

广义线性化

- 线性可分问题往往比线性不可分问题更容易解决!
- 有没有方法能将线性不可分问题转化为线性可分问题呢?



$$\begin{aligned} G(x) &= (x - a)(x - b) \\ G(x) &> 0, x \in \omega_1 \\ G(x) &< 0, x \in \omega_2 \end{aligned}$$

$$G(x) = (x - a)(x - b) = x^2 - (a + b)x + ab$$

$$\text{令 } y_1 = x^2, y_2 = x$$

$$G(x) = y_1 - (a + b)y_2 + ab = g(y_1, y_2)$$

二维特征空间中的线性判别函数!


广义线性化

- 通过非线性变换，将实例从一维空间映射到二维空间中：

$$x \rightarrow \mathbf{y} = (y_1, y_2) = (x^2, x)$$


得到一个线性判别函数：

$$g(y_1, y_2) = y_1 - (a + b)y_2 + ab$$



$$\begin{aligned} a &\rightarrow (a^2, a), \quad g(a^2, a) = 0 \\ b &\rightarrow (b^2, b), \quad g(b^2, b) = 0 \end{aligned}$$


广义线性化



$$G(x) = (x - a)(x - b)$$

$$G(x) > 0, x \in \omega_1$$

$$G(x) < 0, x \in \omega_2$$




$$c \rightarrow (c^2, c)$$

$$g(c^2, c) = (c - a)(c - b)$$

$$\text{if } c \in \omega_1, \quad g(c^2, c) > 0$$

$$\text{if } c \in \omega_2, \quad g(c^2, c) < 0$$


广义线性化



$$G(x) = (x - a)(x - b)$$

$$G(x) > 0, x \in \omega_1$$

$$G(x) < 0, x \in \omega_2$$



$$c \rightarrow (c^2, c)$$

$$g(c^2, c) = (c - a)(c - b)$$

$$\text{if } c \in \omega_1, g(c^2, c) > 0$$

$$\text{if } c \in \omega_2, g(c^2, c) < 0$$

广义线性化

➤ 通过一个非线性变换，我们将

识别问题从 **低维特征空间** → **高维特征空间**

线性不可分 → **线性可分**

这种方法就称为“广义线性化”。

➤ 是不是所有在低维空间中线性不可分的问题，映射到高维空间都可以变成线性可分的问题呢？需要映射到多少维才行呢？


我们后面讲到svm的时候再解答。

线性判别函数值的几何意义

➤ 在 d 维的特征空间中，线性判别函数的一般形式为：

$$G(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$$

\mathbf{w} 是超平面 $\mathbf{w}^T \mathbf{x} + b = 0$ 的法向量。 r 为实例 \mathbf{x} 到决策边界的距离。



① \mathbf{x} 在决策边界正侧

$$\mathbf{x}' + r \cdot \frac{\mathbf{w}}{\|\mathbf{w}\|} = \mathbf{x}$$

$$G(\mathbf{x}') = 0$$

$$\Rightarrow r = \frac{G(\mathbf{x})}{\|\mathbf{w}\|}$$

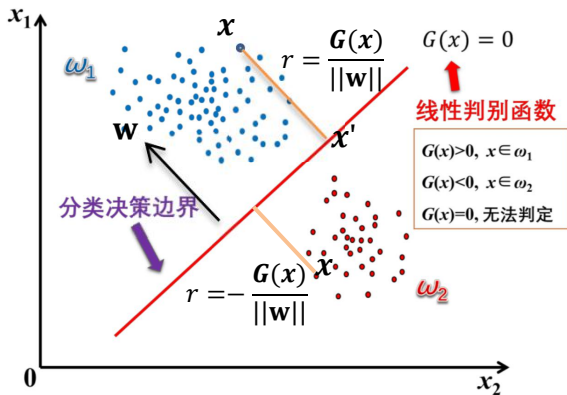
② \mathbf{x} 在决策边界负侧

$$\mathbf{x}' - r \cdot \frac{\mathbf{w}}{\|\mathbf{w}\|} = \mathbf{x}$$

$$G(\mathbf{x}') = 0$$

$$\Rightarrow r = -\frac{G(\mathbf{x})}{\|\mathbf{w}\|}$$


线性判别函数值的几何意义



$$r = \frac{|G(x)|}{\|\mathbf{w}\|}$$

- 判别函数 $G(x)$ 的符号表示实例 \mathbf{x} 位于决策边界的正侧还是负侧。实例 \mathbf{x} 到决策边界的距离 r 正比于判别函数 $G(x)$ 的绝对值。

线性判别函数值的几何意义



- \mathbf{w} 仅代表决策边界的法向量方向，其长度不会影响决策边界在特征空间中的位置，因此完全可以取 $\|\mathbf{w}\| = 1$ ，此时，判别函数的绝对值就是实例到决策边界的距离。

小结

- 线性可分的问题能够通过一个线性判别函数将两类的实例分得开，而线性不可分问题则不能。
- 在低维特征空间中线性不可分的问题，可以通过非线性变换，映射到高维特征空间中变成线性可分的问题，这称为“广义线性化”。
- 线性判别函数的一般形式为：

$$G(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$$

其中 \mathbf{w} 称为权向量， b 称为偏置。 $\mathbf{w}^T \mathbf{x} + b = 0$ 是一个超平面的方程， \mathbf{w} 是该超平面的法向量。

重点

小结

- 一个线性判别函数 $G(x)$ 只能将特征空间划分为**两个**决策域: $G(x) > 0$ 和 $G(x) < 0$, 因此只能用于二分类问题。
- 线性判别函数值的几何意义是:

实例 \mathbf{x} 的判别函数的绝对值, 即 $|G(\mathbf{x})|$, 正比于该实例到分类决策边界 $G(x) = 0$ 的距离。

重点